TOKYO 2020

도쿄 올림픽 EDA 및 머신러닝 모델 만들기

메달 개수에 따른 순위예측 모델 & 정보입력시 해당 팀명 출력 모델

2 1 3

CONTENTS

1 도쿄 올림픽 2020 EDA

- 데이터 개요
- 선수 분석
- 메달분석
- 참가자 성별 분석

2 데이터 전처리

- 데이터 라벨링

3 머신러닝 모델 만들기

(1) 메달 개수에 따른 순위예측 모델

- 기본모델(KNN모델) 성능개선
- 여러가지 모델 비교

(2) 정보입력시 해당 팀명 출력 모델

- 기본모델(KNN모델) 만들기

4 결론

도쿄 올림픽 EDA

데이터 출처 : 캐글 도쿄올림픽2020 데이터
URL : https://www.kaggle.com/arjunprasadsarkhel/2021-olympics-in-tokyo

01 도쿄 올림픽 EDA **데이터 개요**

: 2021(2020) 도쿄 올림픽에 참가하는 743개 팀과 함께 47개 종목의 11,000명이 넘는 선수의 세부 정보를 담고 있다.

데이터 정보확인

```
athlete.info(), gender.info(), medal.info()
```

컬럼 정보 및 결측치 확인

```
print(athlete.nunique())
print("------------------")
print(gender.nunique())
print("------------------")
print(medal.nunique())
print("------------------")
```

```
print(athlete.isnull().sum())
print("------------------")
print(gender.isnull().sum())
print("------------------")
print(medal.isnull().sum())
print("------------------")
```

데이터 요약 표

	column 정보	column 수	data type	결측치
선수	선수이름,나라,출전종목	3 column	object(문자열)	X
메달	출전종목,성별(남,여,합계)	7 column	object(문자열), int(정수형)	X
성별	순위,나라,메달개수 (금,은,동,합계)	4 column	object(문자열), int(정수형)	X

- 세 데이터 모두 결측치가 없으며, 선수 데이터는 모든 column이 문자열로 이루어졌있다.
  - 메달과 성별 데이터는 종목/팀 column을 제외 모두 정수형으로 이루어져 있음.

2 1 3

01 도쿄 올림픽 EDA **선수 분석**

```
x = athlete.NOC.value_counts()
```

```
px.bar(x[:20], title="나라별 참가자수 상위 20")
```

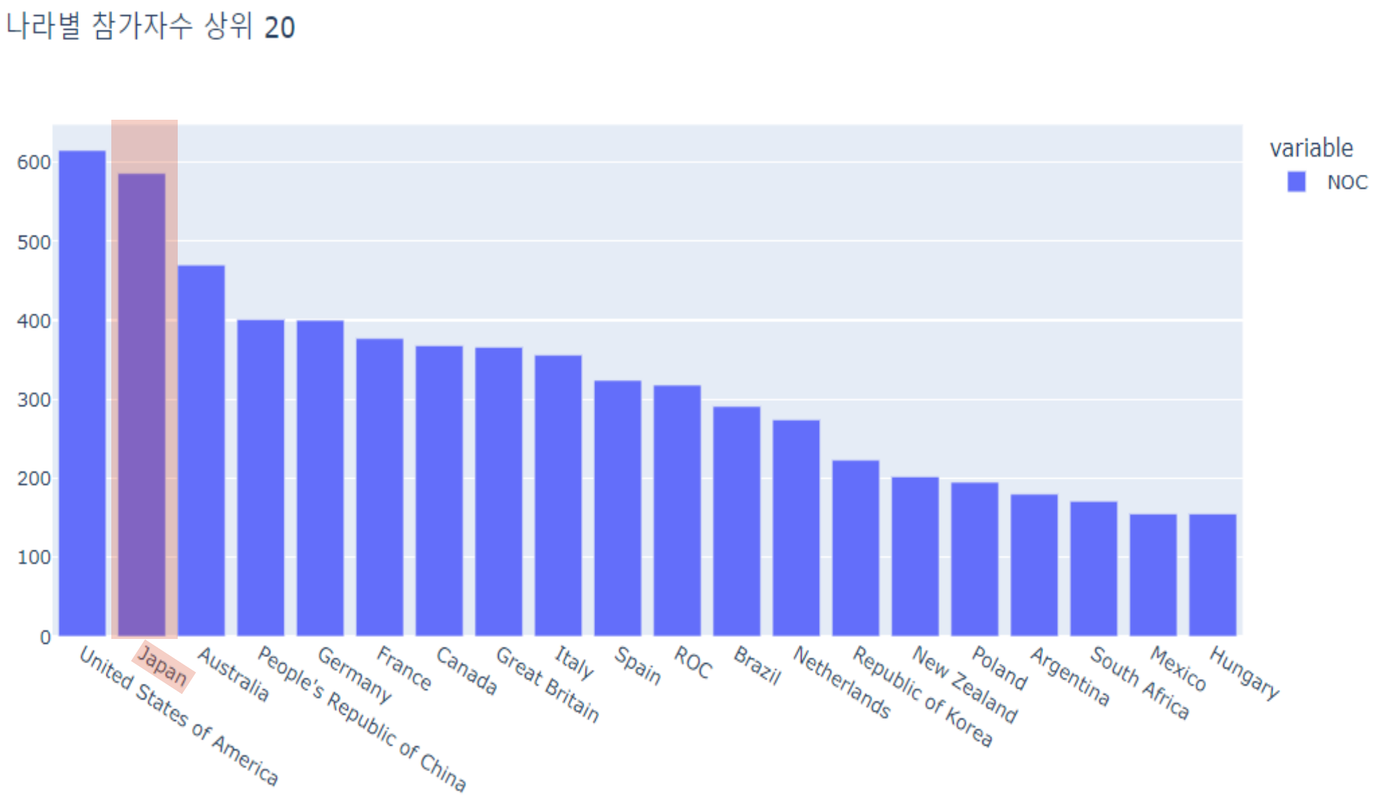

- 미국,일본,호주 순으로 많은 선수가 참가하였다.
- 참가자 상위20위 안에 일본을 제외한 **아시아 국가는 없다.**

2 1 3

01 도쿄 올림픽 EDA **메달 분석**

금메달 개수 은메달 개수 동메달 개수 전체메달 개수

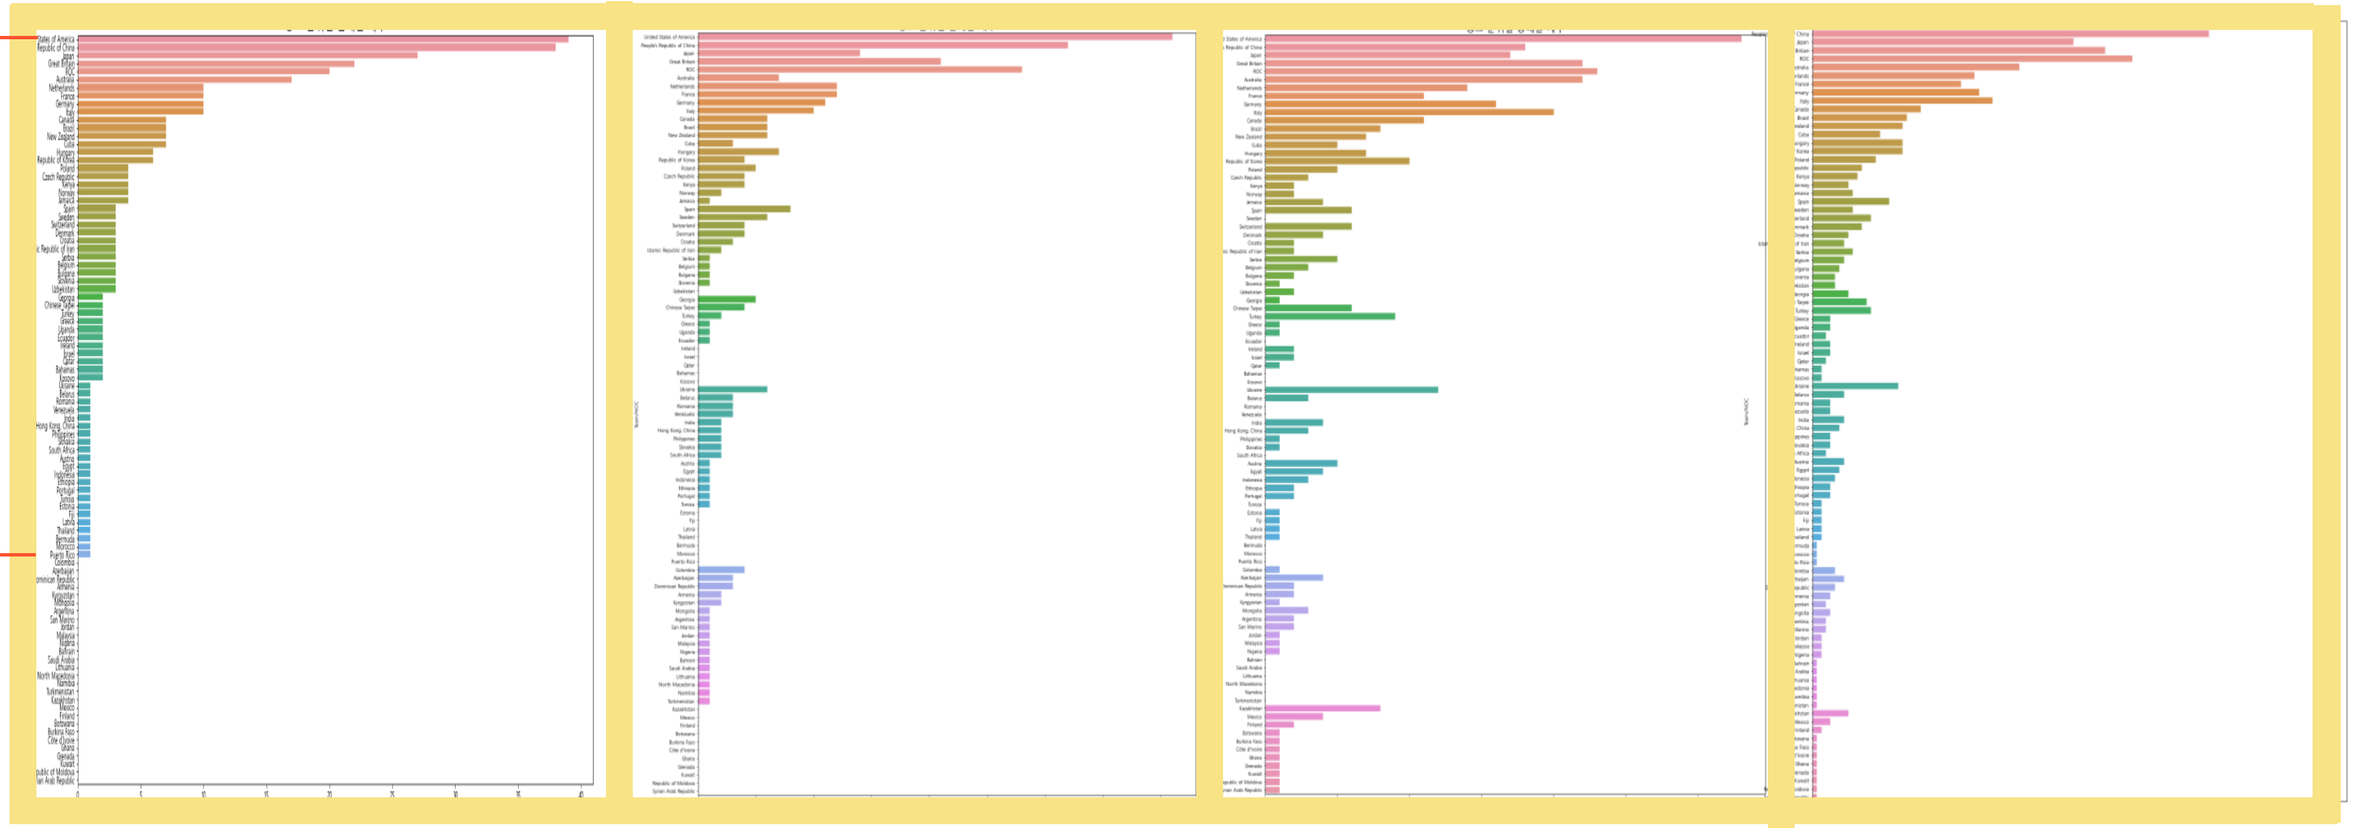

- 올림픽 랭크 순위대로 금메달이 많다.
- 올림픽 랭크는 **전체 메달 수와 무관**하다.

2 1 3

01 도쿄 올림픽 EDA **메달 분석**

```
px.bar(medal[:20], x="Team/NOC", y="Total", color="Silver",
       title="상위 20개국의 전체 메달 및 은메달 비율 ")
```

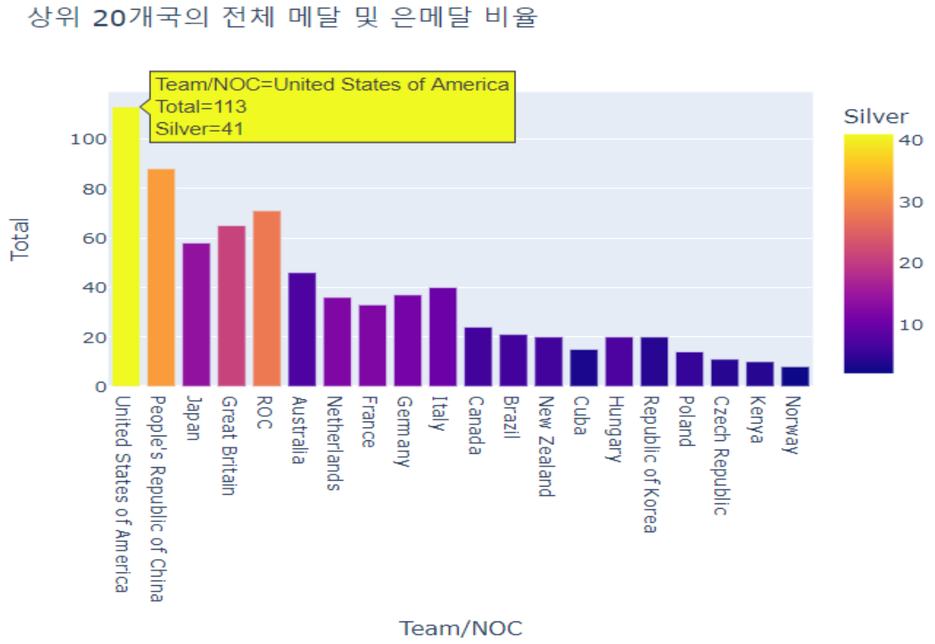


```
px.bar(medal[:20], x="Team/NOC", y="Total", color="Bronze",
       title="상위 20개국의 전체 메달 및 동메달 비율 ")
```

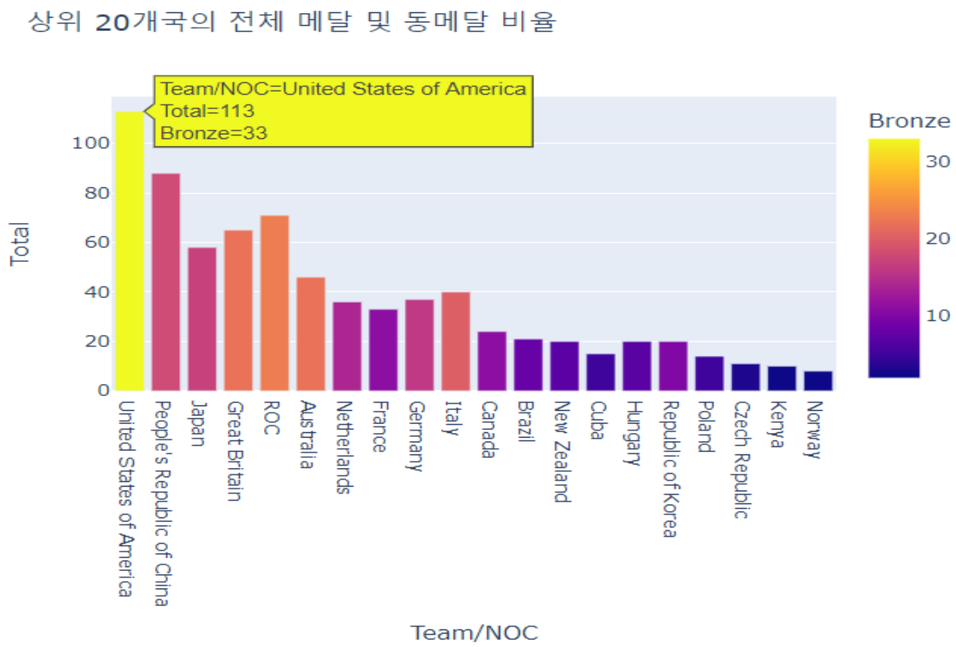

- 올림픽 랭크 순위는 **은메달 동메달 비율과 무관**하다.

2 1 3

01 도쿄 올림픽 EDA **성별 분석**

```
sns.lmplot(x='Female', y='Male', data=gender, size=7)
plt.title("남성참가자와 여성참가자의 수의 따른 그래프", fontsize=15)
plt.show()
```

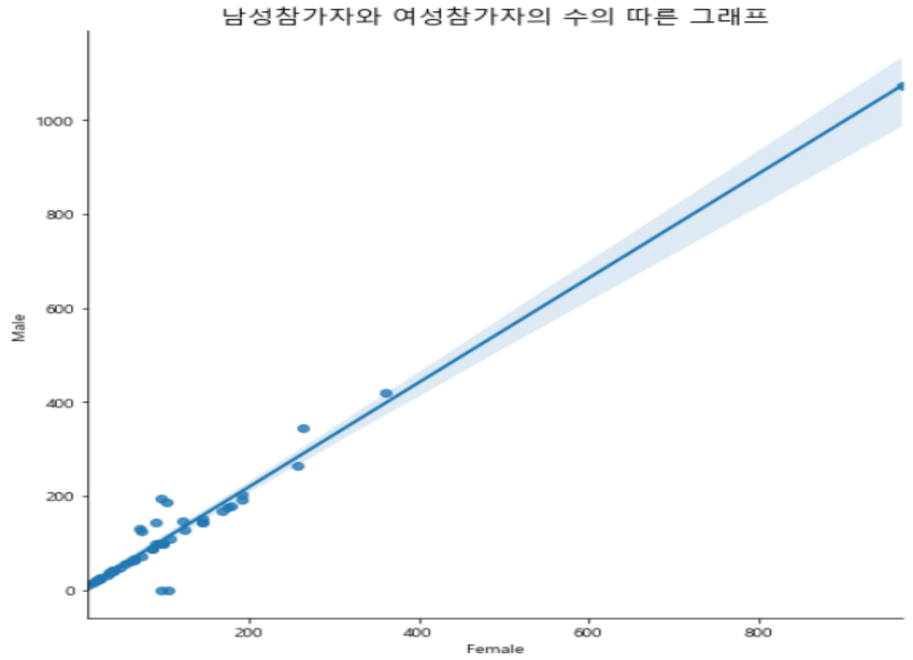


```
sns.histplot(gender.Male)
plt.title("남성참가자 도수분포 그래프", fontsize=15)
```

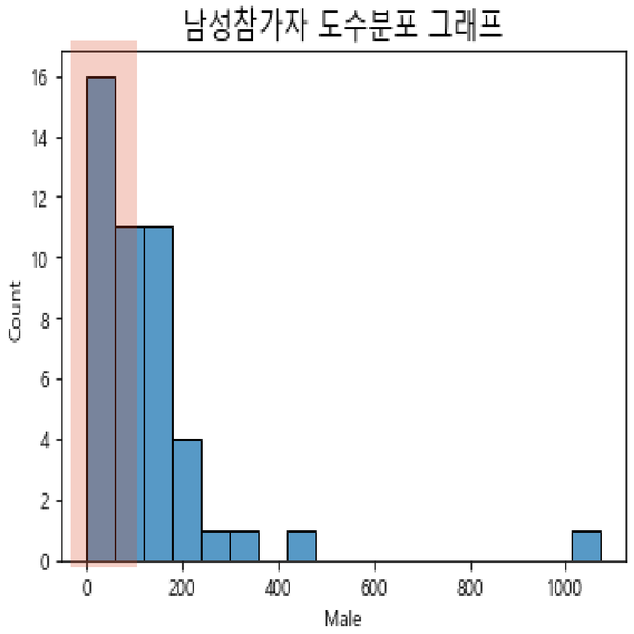


```
sns.histplot(gender.Female)
plt.title("여성참가자 도수분포 그래프", fontsize=15)
```

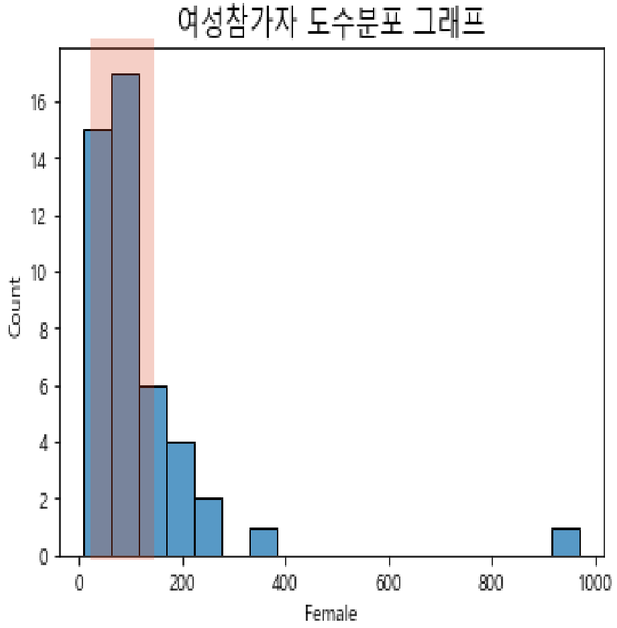

- 남성참가자와 여성참가자의 수는 대등하다.
  - 400명 이상 참가하는 종목은 거의 없다.
- 종목별 로 여성 참가자는 [100명 이하 참가자] 남성 참가자는 [약70명 이하] 참가자가 가장 많다.

2 1 3

01 도쿄 올림픽 EDA **성별 분석**

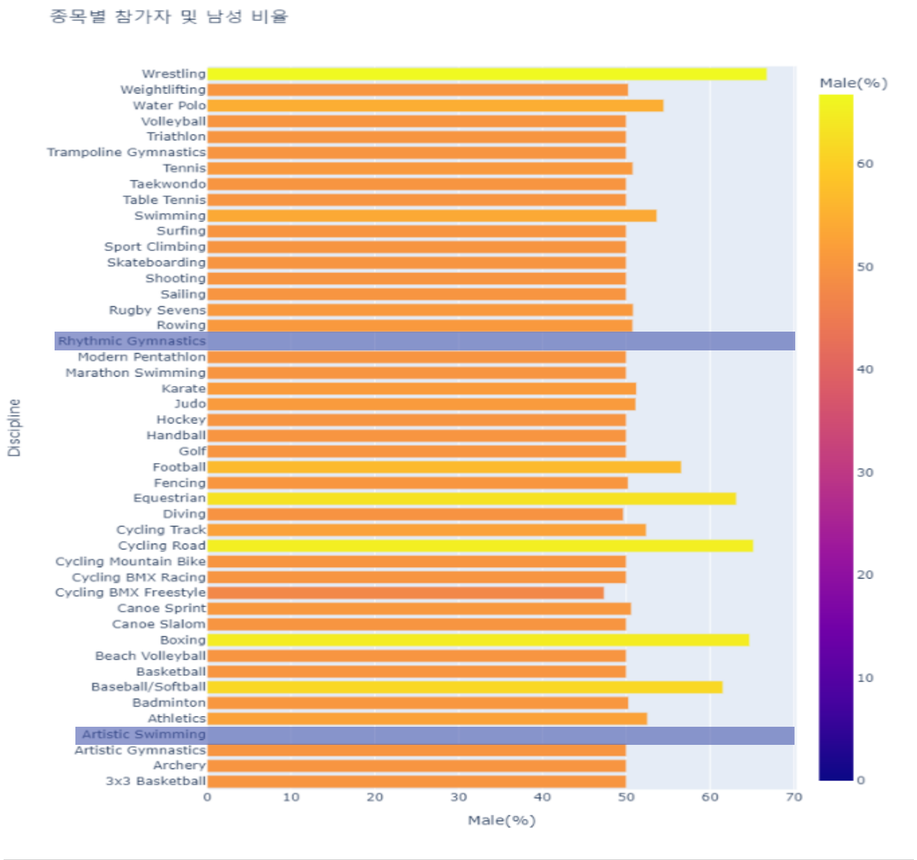

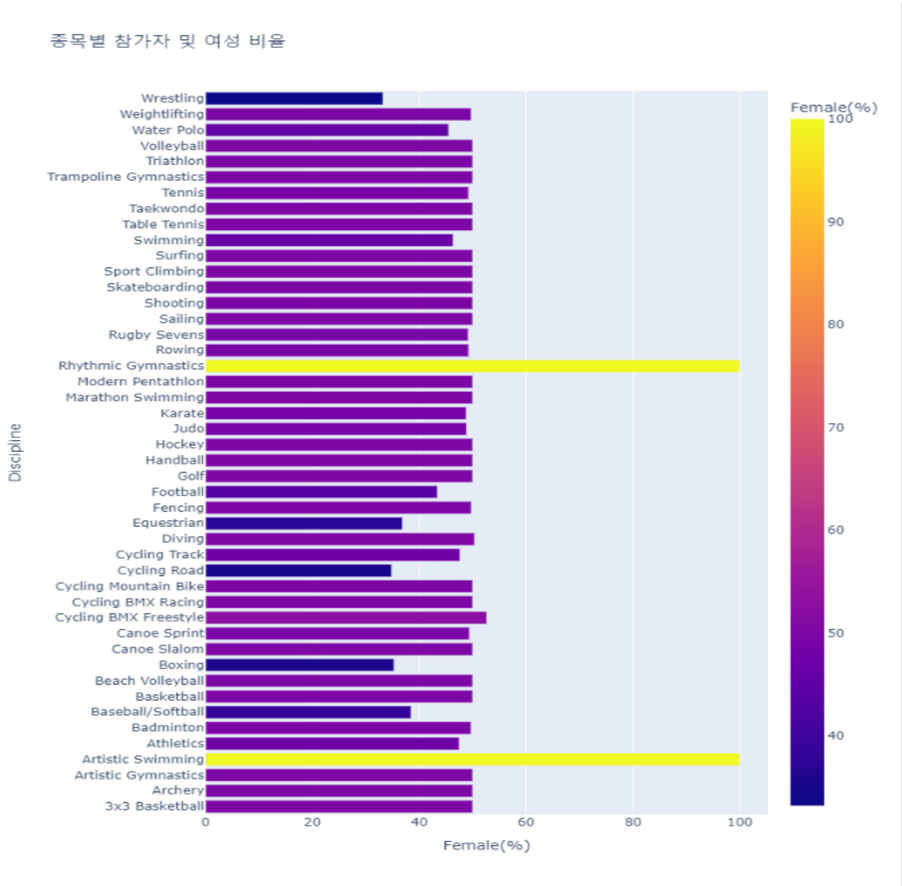

2 1 3

- 여성은 **전종목에 참여**하였지만, **남성**은 **두 종목**의 경기([Artistic Swimming], [Rhythmic Gymnastics])에 **참가하지 않았다.**
- 대부분 종목에서 남성의 비율이 절반(50%) 이상이다. 그 중 가장 많은 비율의 남성이 참가한 종목은 [Wrestling]이다.

01 도쿄 올림픽 EDA **성별 분석**

[성별 비율] 새로운 column 추가

```
gender["Female(%)"] = gender['Female'] / gender['Total'] * 100
gender["Male(%)"] = gender['Male'] / gender['Total'] * 100
gender.head()
```

[여성 > 남성] 데이터 추출

```
gender_2 = gender.loc[(gender.Female > gender.Male), :]
gender_2
```

	Discipline	Female	Male	Total	Female(%)	Male(%)
3	Artistic Swimming	105	0	105	100.000000	0.000000
12	Cycling BMX Freestyle	10	9	19	52.631579	47.368421
17	Diving	72	71	143	50.349650	49.650350
28	Rhythmic Gymnastics	96	0	96	100.000000	0.000000

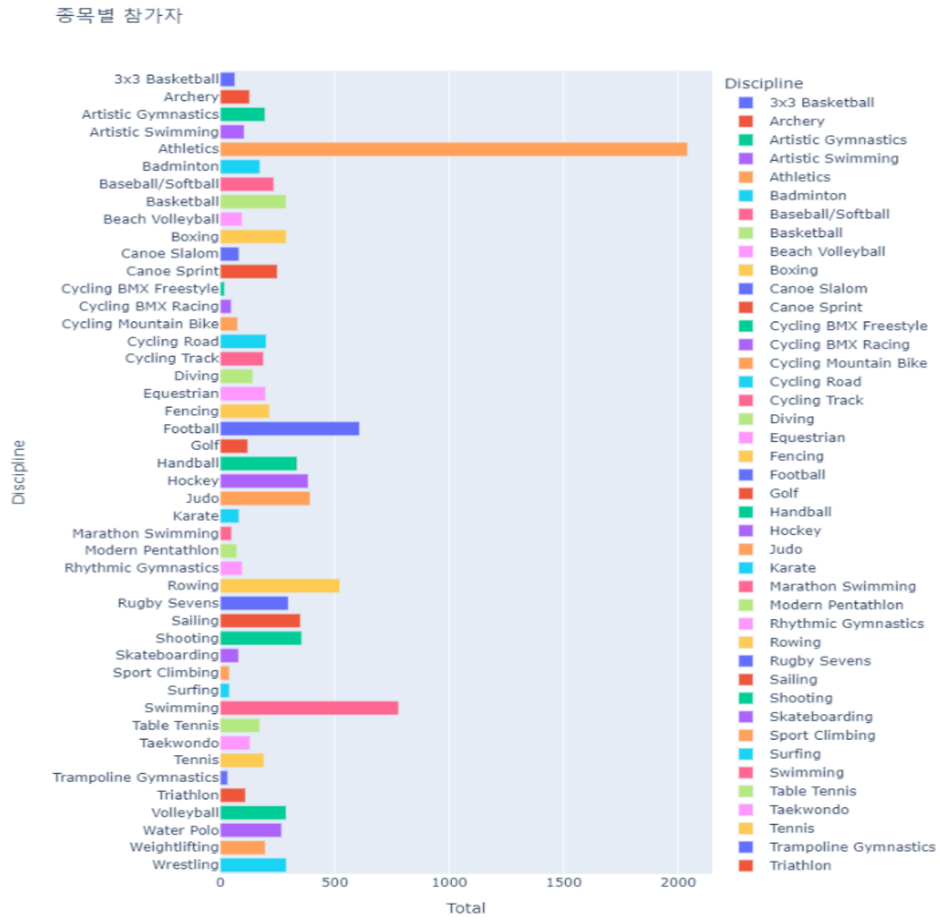

- 전체 46종목중 여성 참가자가 더 많은 종목은 4종목이다.
- 그 중 [Artistic Swimming]과 [Rhythmic Gymnastics]는 여성 참가자만 있다.

2 1 3

02

데이터 전처리

02 데이터 전처리 **데이터 라벨링**

[나라명 라벨링] 새로운 컬럼 추가

```
ex_x = LabelEncoder()
medal['Team/NOC_lbl'] = ex_x.fit_transform(medal['Team/NOC'])
medal
```

	Rank	Team/NOC	Gold	Silver	Bronze	Total	Rank by Total	Team/NOC_lbl
0	1	United States of America	39	41	33	113	1	90
1	2	People's Republic of China	38	32	18	88	2	64
2	3	Japan	27	14	17	58	5	45
3	4	Great Britain	22	21	22	65	4	33
4	5	ROC	20	28	23	71	3	70
...	...	...	...	...	...	...	...	...
88	86	Ghana	0	0	1	1	77	32
89	86	Grenada	0	0	1	1	77	35
90	86	Kuwait	0	0	1	1	77	50
91	86	Republic of Moldova	0	0	1	1	77	72
92	86	Syrian Arab Republic	0	0	1	1	77	83

- 범주형 column(나라명) 을 수치형column(나라명 라벨링) 으로 변경
- 두 번째 모델(정보입력시 해당 팀명 출력 모델)의 정확도를 높이기 위함

2 1 3

03

머신러닝 모델

03 머신러닝 모델 (1) 메달 개수에 따른 순위예측 모델

- 기본모델(KNN모델) 만들기

1. 데이터 나누기

```
sel = ['Gold', "Silver", "Bronze" ]

X_n = medal[sel]
y_n = medal['Rank']

X_n_train, X_n_test, y_n_train, y_n_test = train_test_split(X_n,y_n,
                                                            random_state=1)
```

2. KNN 모델 학습

```
knn = KNeighborsClassifier()
knn.fit(X_n_train,y_n_train)
```

3. KNN 모델 적합도(결정계수) 구하기

```
knn_tr = knn.score(X_n_train, y_n_train)
knn_test = knn.score(X_n_test, y_n_test)
```

```
print("훈련 데이터셋 적합도 : {:.2f}".format(knn_tr))
print("테스트 데이터 셋 적합도도 : {:.2f}".format(knn_test))
```

```
훈련 데이터셋 적합도 : 0.41
테스트 데이터 셋 적합도도 : 0.25
```

03 머신러닝 모델 **기본모델(KNN모델) 성능 개선**

- k값에 따른 적합도 구하기

```
tr_knn = []
test_knn = []
k_nums = range(1,22,2)

for n in k_nums:
    knn = KNeighborsClassifier(n_neighbors=n)
    knn.fit(X_n_train,y_n_train)

    knn_tr = knn.score(X_n_train, y_n_train)
    knn_test = knn.score(X_n_test, y_n_test)

    tr_knn.append(knn_tr)
    test_knn.append(knn_test)

    print("k :", n)
    print("학습용셋 적합도 : {:.3f}".format(knn_tr))
    print("테스트용 셋 적합도 : {:.3f}".format(knn_test))
```

	train_score	test_score
1	1.000000	0.416667
3	0.463768	0.291667
5	0.405797	0.250000
7	0.376812	0.250000
9	0.246377	0.208333
11	0.188406	0.208333
13	0.159420	0.208333
15	0.159420	0.208333
17	0.086957	0.041667
19	0.086957	0.041667
21	0.086957	0.041667

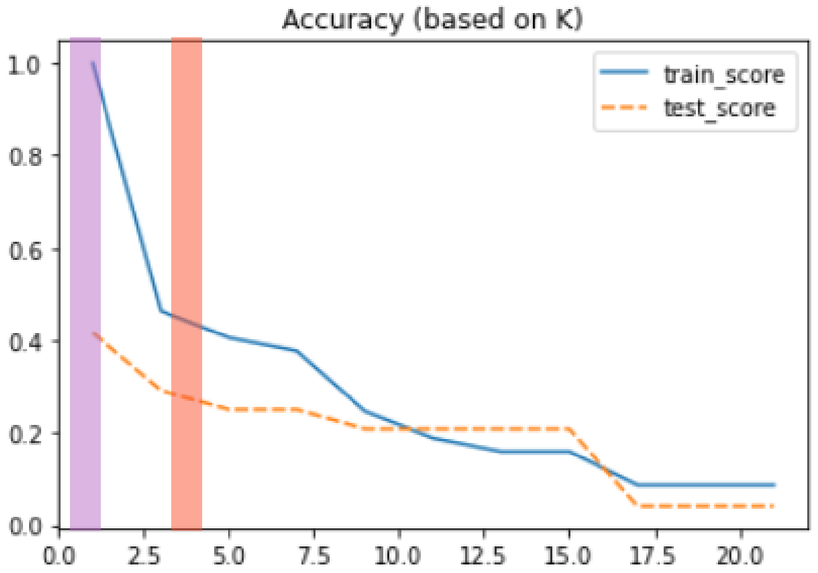

train 적합도는 k=1일때 가장 높지만, test 셋과의 **적합도 차이가 많이**나므로 **과적합됨**을 알 수 있다.
따라서, k=3일 때 가장 높은 적합도를 보이므로 **k=3을 채택**한다.

2 1 3

03 머신러닝 모델 기본모델(KNN모델) 성능 개선

기본 모델 적합도
훈련 데이터셋 적합도 : 0.41
테스트 데이터셋 적합도 : 0.25

- test_size에 따른 적합도 구하기

```
for i in range(1,6,1):
    X_n_train, X_n_test, y_n_train, y_n_test = train_test_split(X_n,y_n,
                                                test_size=(i/10),
                                                random_state=3)
    knn = KNeighborsClassifier(n_neighbors=1).fit(X_n_train,y_n_train)

    tr_score = knn.score(X_n_train,y_n_train)
    test_score = knn.score(X_n_test,y_n_test)
    print("학습용 : {}, 테스트용 : {}".format(10-i, i))
    print("학습용 : {:.3f}, 테스트용 : {:.3f}₩n ".format(tr_score, test_score))
```

```
학습용 : 9, 테스트용 : 1
학습용 : 1.000, 테스트용 : 0.500

학습용 : 8, 테스트용 : 2
학습용 : 1.000, 테스트용 : 0.526

학습용 : 7, 테스트용 : 3
학습용 : 1.000, 테스트용 : 0.500

학습용 : 6, 테스트용 : 4
학습용 : 1.000, 테스트용 : 0.395

학습용 : 5, 테스트용 : 5
학습용 : 1.000, 테스트용 : 0.362
```

- total feature 추가

```
sel_t = ['Gold', "Silver", "Bronze" ,"Total"]

X_t = medal[sel_t]
y_t = medal['Rank']

X_t_train, X_t_test, y_t_train,
y_t_test=train_test_split(X_t,y_t,random_state=1)
```

```
print("훈련 데이터셋 적합도 : {:.2f}".format(knn_t_tr))
print("테스트 데이터 셋 적합도 : {:.2f}".format(knn_t_test))
```

```
훈련 데이터셋 적합도 : 0.41
테스트 데이터 셋 적합도 : 0.29
```

test_size와 관계없이 학습용 셋의 적합도는 변화가 없으므로 테스트용 셋 적합도가 가장 높은 **8:2 비율**을 채택한다.
total(전체메달수)를 feature에 추가함으로서 성능이 약간 향상됨을 알 수 있다.

2 1 3

03 머신러닝 모델 **기본모델(KNN모델) 성능 개선**

기본 모델 적합도
훈련 데이터셋 적합도 : 0.41
테스트 데이터셋 적합도 : 0.25

- 가중치 값을 통한 성능개선

```
medal['Gold_1000'] = medal['Gold'] * 1000
medal['Silver_100'] = medal['Silver'] * 100
medal['Bronze_10'] = medal['Bronze'] * 10
```

Gold X 1000 , Silver X 100, Bronze X 10
각 각 가중치를 두어 새로운 colmn 생성

- 가중치 값 조절 후 적합도

```
knn_1000_tr = knn_1000.score(X_1000_train, y_1000_train)
knn_1000_test = knn_1000.score(X_1000_test, y_1000_test)
```

```
print("훈련 데이터셋 적합도 : {:.2f}".format(knn_1000_tr))
print("테스트 데이터 셋 적합도 : {:.2f}".format(knn_1000_test))
```

```
훈련 데이터셋 적합도 : 0.41
테스트 데이터 셋 적합도 : 0.25
```

가중치 값과 무관하게 이전 기본모델과 적합도가 같음.
따라서 **가중치값에 따른 성능개선이 되지 않음.**

2 1 3

03 머신러닝 모델 **다양한 모델 비교**

MSE : 평균제곱오차

$$MSE = 1/n \sum_{i=1}^{n} (\text{실제값} - \text{예측값})^2$$

KNeighborsClassifier, LogisticRegression, LinearSVC, RandomForestClassifier, DecisionTreeClassifier, GradientBoostingClassifier 모델

	모델	적합도	오차	MSE
0	KNN 모델	0.7	0.300000	29.7
1	Logistic 모델	0.2	0.378313	314.9
2	SVC 모델	0.5	-0.078313	151.9
3	RF 모델	0.7	0.300000	1.8
4	D.tree모델	0.7	0.300000	56.3
5	Gradient 모델	0.7	0.300000	18.2

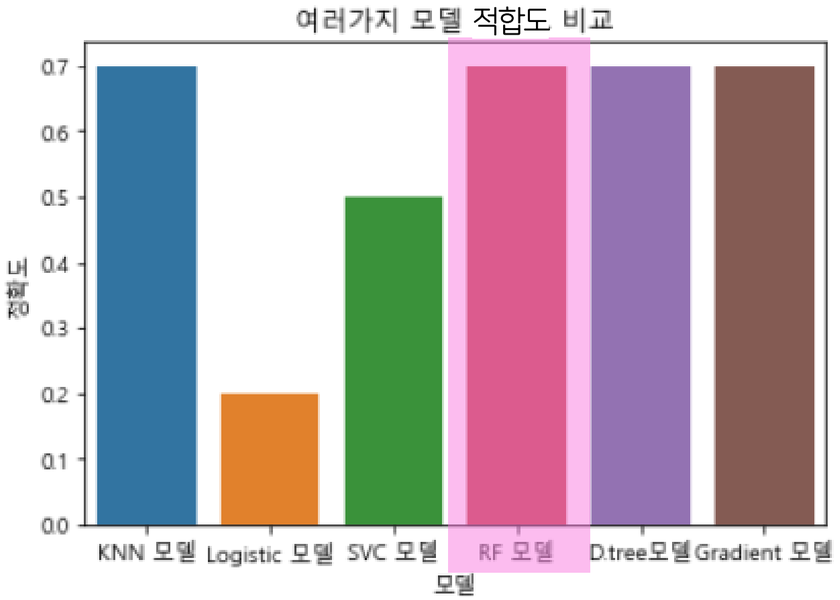

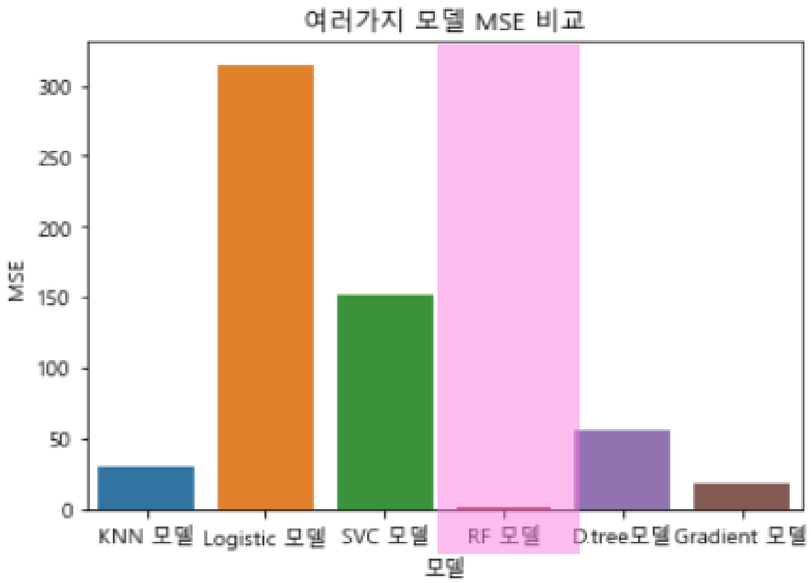

logistic 모델과 SVC 모델을 제외한 모든 모델들의 적합도도가 0.7로 가장 높았다.
MSE가 가장 낮게 나온 모델은 RandomForestClassifier 모델로 수치는 1.80이다.
따라서 , 가장 **최적의 모델**은 **RandomForestClassifier**이다.

2 1 3

03 머신러닝 모델 (2) 정보입력시 해당 팀명 출력 모델

금,은,동 메달 개수입력 시 해당 나라명 출력하는 모델

1. 데이터 나누기

```
sel = ['Gold','Silver','Bronze']
X = medal[sel]
y = medal['Team/NOC_lbl']

X_train, X_test, y_train, y_test = train_test_split(X,y,
                                                    test_size = 0.1,
                                                    random_state = 0)
```

2. 데이터 입력받기

```
print("금,은,동메달의 개수를 입력하세요")
a, b, c = input().split()
inp_value = [a,b,c]
```

3. 데이터 출력

```
pred = model.predict([inp_value])
pred[0]
```

4. loc를 통해 해당 출력받은 데이터와 일치하는 나라명 출력

```
sel_medal = medal.loc[medal['Team/NOC_lbl'] == pred[0], "Team/NOC"]
print("예측 나라는 :", sel_medal.values)
```

```
예측 나라는 : ['Botswana']
```

2 1 3

04 결론

04 결론

도쿄올림픽 대부분 출전국가는 유럽 및 아메리카이며, 선수 성비는 남자가 약간 우세하다. 또한 여성은 올림픽 전종목에 출전하였다.

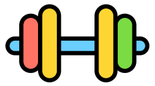

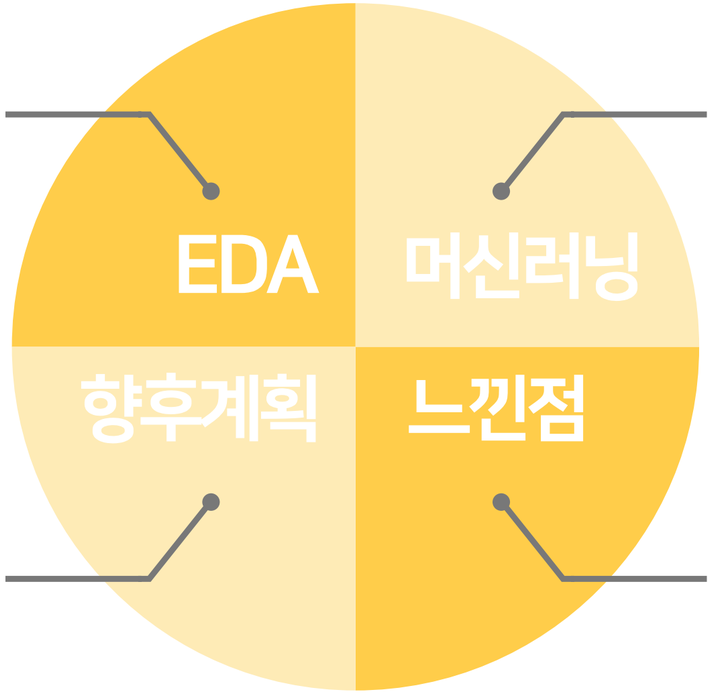

최적의 모델의 위한 K값은 3이며, 학습용과 테스트용셋의 최적 비율은 8:2이다.
대부분 모델이 정확도가 비슷하지만 R/F모델이 mse가 가장 낮아 최적모델이다.

- EDA : 지도 시각화 및 가설설정하여 심도있는 분석 진행
- 머신러닝 : feature 추가를 통한 성능개선 및 추가 모델 비교

파이썬 라이브러리를 활용하여 데이터를 분석하면서 그간 배웠던 내용을 복습할 수 있었다.
또한 머신러닝 모델을 만들고 성능개선 및 비교를 통해 ML 기본에 대해 이해할 수 있었다.

2 1 3

감사합니다